

CONTENTS

Introduction to Machine Learning — 예상 시험 & 모범답안	
UNLV · Prof. Mingon Kang · 영문 문제 + 한글 번역 + 모범답안	
Part 1. True / False (10문항)	
Part 2. Short Answer (5문항)	
Part 3. Essay (3문항)	
Part 4. Problem Solving (2문항)	
시험 직전 핵심 체크 (우선순위)	

Introduction to Machine Learning — 예상 시험 & 모범답안

UNLV · PROF. MINGON KANG · 영문 문제 + 한글 번역 + 모범답안

시험 형식: 총 20문항 — True/False 10 · Short Answer 5 · Essay 3 · Problem Solving 2.
전부 영어, 계산기·노트 불가. 아래는 리뷰세션 강조 내용 + 교수님 연구 취향(불균형 데이터·평가 지표·딥러닝)을 반영한 예상 문제와 모범답안입니다.

Part 1. True / False (10문항)

Q1. A single perceptron can solve the XOR problem.

- (한글) 단일 퍼셉트론은 XOR 문제를 풀 수 있다.
- **정답: False (거짓)**
- **Why:** XOR is not linearly separable, and a single perceptron can only draw one linear boundary.
- (한글) XOR은 선형 분리가 불가능한데, 단일 퍼셉트론은 직선(초평면) 하나만 그을 수 있어 풀 수 없다.

Q2. The number of nodes in the input layer can be chosen freely by the designer.

- (한글) 입력층 노드 수는 설계자가 임의로 정할 수 있다.
- **정답: False (거짓)**
- **Why:** The number of input nodes must equal the number of input features.
- (한글) 입력 노드 수는 데이터의 feature(특징) 개수와 같아야 한다.

Q3. Logistic regression has a closed-form solution like OLS.

- (한글) 로지스틱 회귀는 OLS처럼 닫힌 형태(closed-form)의 해가 있다.
- **정답: False (거짓)**
- **Why:** Logistic regression has no closed form; it is solved iteratively via MLE / gradient descent.

- (한글) 로지스틱 회귀는 닫힌 해가 없고, 최대우도추정(MLE)을 gradient descent로 근사해 본다.

Q4. Increasing K in KNN makes the decision boundary smoother.

- (한글) KNN에서 K를 크게 하면 결정 경계가 부드러워진다.
- **정답: True (참)**
- **Why:** A larger K averages over more neighbors, smoothing the boundary and reducing overfitting.
- (한글) K가 크면 더 많은 이웃을 반영해 경계가 부드러워지고 과적합이 줄어든다. (K가 작으면 과적합.)

Q5. Accuracy is a reliable metric for highly imbalanced datasets.

- (한글) 정확도(accuracy)는 불균형이 심한 데이터에서 신뢰할 만한 지표이다.
- **정답: False (거짓)**
- **Why:** With e.g. 9990:10 data, predicting all-majority gives 99.9% accuracy yet is useless. Use precision/recall/F1.
- (한글) 예로 9990:10 데이터에서 전부 다수클래스로 찍어도 정확도 99.9% → 무의미. precision/recall/F1을 써야 한다.

Q6. Normalization parameters (mean/std) should be estimated using both training and test data.

- (한글) 정규화 파라미터(평균/표준편차)는 훈련+테스트 데이터를 함께 써서 계산해야 한다.
- **정답: False (거짓)**
- **Why:** Fit on the training set only and apply to the test set; using test data causes data leakage.
- (한글) 훈련 데이터로만 계산해 테스트에 적용한다. 테스트를 쓰면 정보 누수(data leakage)다.

Q7. The gradient ∇f points in the direction of steepest descent.

- (한글) 그래디언트 ∇f 는 가장 가파르게 감소하는 방향을 가리킨다.
- **정답: False (거짓)**
- **Why:** ∇f points in the direction of steepest ascent; gradient descent moves in the negative gradient direction.
- (한글) ∇f 는 가장 가파르게 증가하는 방향이다. 경사하강법은 그 반대(음의) 방향으로 이동한다.

Q8. AlexNet was the first convolutional neural network ever proposed.

- (한글) AlexNet은 최초로 제안된 CNN이다.
- **정답: False (거짓)**
- **Why:** LeNet (LeCun, 1990s) came first; AlexNet (2012) popularized CNNs.
- (한글) 최초는 LeNet(LeCun, 1990년대). AlexNet(2012)은 CNN을 대중화시킨 사례다.

Q9. In Ridge regression, $(X'X + \lambda I)$ is always invertible.

- (한글) Ridge 회귀에서 $(X'X + \lambda I)$ 는 항상 역행렬이 존재한다.
- **정답: True (참)**
- **Why:** Adding λI ($\lambda > 0$) makes the matrix positive-definite, so Ridge always has a unique solution even under multicollinearity.
- (한글) λI ($\lambda > 0$)를 더하면 양의 정부호가 되어 항상 역행렬 존재 → 다중공선성에도 유일해를 가진다.

Q10. In K-fold cross-validation, the held-out fold is used to train the model.

- (한글) K-겹 교차검증에서 남겨둔 fold는 모델 학습에 사용된다.
- **정답: False (거짓)**
- **Why:** The held-out fold is used for testing; the other $K-1$ folds are used for training.
- (한글) 남긴 fold는 테스트용이고, 나머지 $K-1$ 개로 학습한다.

Part 2. Short Answer (5문항)

Q11. Explain the difference between multi-class and multi-label classification.

- (한글) 다중클래스 분류와 다중라벨 분류의 차이를 설명하라.
- **Answer:** In multi-class classification each sample has exactly **one** label chosen from three or more classes. In multi-label classification each sample can have **several** labels at the same time.
- (한글) 다중클래스는 샘플당 라벨이 **정확히 1개**(클래스는 3개 이상). 다중라벨은 샘플 하나가 **여러 라벨**을 동시에 가질 수 있다.

Q12. How is the number of output-layer nodes decided for binary, multi-class, and regression problems?

- (한글) 이진분류·다중클래스·회귀에서 출력층 노드 수는 어떻게 정하는가?
- **Answer:** Binary → 1 node (sigmoid) or 2 (softmax). Multi-class → one node per class (softmax). Regression → 1 node (linear, no activation). The output layer is determined by *what* you predict.
- (한글) 이진분류→1개(sigmoid) 또는 2개(softmax), 다중클래스→클래스 개수만큼(softmax), 회귀→1개(활성화 없이 linear). 출력층은 “무엇을 예측하느냐”로 결정된다.

Q13. State one cause and one solution of the vanishing gradient problem.

- (한글) 기울기 소실(vanishing gradient) 문제의 원인 하나와 해결책 하나를 쓰라.
- **Answer:** Cause — in deep networks, gradients shrink exponentially as they pass through many layers (especially with sigmoid, whose derivative is small, multiplied via the chain rule). Solution — use ReLU activation and/or Batch Normalization.
- (한글) 원인: 깊은 층을 거치며 chain rule로 작은 값이 계속 곱해져 기울기가 지수적으로 작아짐 (특히 sigmoid). 해결: ReLU 활성화, Batch Normalization 등.

Q14. Why is standardization important for a distance-based model such as KNN?

- (한글) KNN 같은 거리 기반 모델에서 표준화(standardization)가 왜 중요한가?
- **Answer:** KNN decisions depend on distances, so features with larger numeric scales dominate the distance. Standardization puts all features on the same scale so each contributes fairly.
- (한글) KNN은 거리로 판단하는데, 스케일이 큰 feature가 거리를 지배해버린다. 표준화로 모든 feature를 같은 범위로 맞춰 공정하게 반영되게 한다.

Q15. What is the role of the parameter C in soft-margin SVM?

- (한글) 소프트마진 SVM에서 파라미터 C의 역할은?
- **Answer:** C controls the trade-off between margin width and misclassification. Large C penalizes errors heavily (narrow margin, strict); small C tolerates more errors (wider margin).
- (한글) C는 margin 폭과 오분류 사이의 트레이드오프를 조절한다. C가 크면 오류에 큰 페널티 (margin 좁고 엄격), 작으면 오류 허용 (margin 넓음).

Part 3. Essay (3문항)

Q16. Describe the backpropagation algorithm in its five steps (including the forward pass), and explain why backpropagation is needed.

- (한글) 역전파 알고리즘의 5단계를 순전파 포함해 설명하고, 역전파가 왜 필요한지 설명하라. (최/우선 출제)

Answer (English):

1. **Input** — set the input-layer activation $a^1 = x$.
2. **Feedforward** — for each layer l , compute the weighted sum $z^l = W^l a^{(l-1)} + b^l$ and the activation $a^l = f(z^l)$, up to the output layer, then compute the cost C from the output a^L and target y .
3. **Output error** — $\delta^L = \partial C / \partial a^L \odot f'(z^L)$.
4. **Backpropagate the error** — for $l = L-1, \dots, 2$: $\delta^l = ((W^{(l+1)})^T \delta^{(l+1)}) \odot f'(z^l)$.
5. **Update** — gradients are $\partial C / \partial W^l = \delta^l (a^{(l-1)})^T$ and $\partial C / \partial b^l = \delta^l$; update parameters by gradient descent. **Why needed:** A neural network has a very large number of parameters, so computing each gradient independently is extremely expensive. Backpropagation uses the **chain rule** together with **dynamic programming** (reusing the intermediate errors δ) to compute the gradients of *all* parameters in a single backward pass.

모범답안 (한글):

1. **입력:** 입력층 활성화값 $a^1 = x$ 로 설정.
2. **순전파:** 각 층에서 가중합 $z^l = W^l a^{(l-1)} + b^l$ 과 활성화 $a^l = f(z^l)$ 을 출력층까지 계산하고, 출력 a^L 과 정답 y 로 비용 C 계산.
3. **출력층 오차:** $\delta^L = \partial C / \partial a^L \odot f'(z^L)$.
4. **오차 역전파:** $l = L-1, \dots, 2$ 에 대해 $\delta^l = ((W^{(l+1)})^T \delta^{(l+1)}) \odot f'(z^l)$.
5. **가중치·편향 갱신:** $\partial C / \partial W^l = \delta^l (a^{(l-1)})^T$, $\partial C / \partial b^l = \delta^l$ 를 이용해 gradient descent로 갱신. **왜 필요한가:** 신경망은 파라미터가 매우 많아 각 gradient를 하나씩 직접 계산하면 비효율적이다. 역전파는 **연쇄법칙(chain rule)** + **동적계획법**(중간 오차 δ 재사용)으로 모든 파라미터의 gradient를 한 번의 역방향 계산으로 효율적으로 구한다.

Q17. Explain why a single perceptron is insufficient and why a multi-layer perceptron (MLP) is needed, using XOR as an example.

- (한글) 단일 퍼셉트론이 왜 부족하고 왜 다층 퍼셉트론(MLP)이 필요한지 XOR 예시로 설명하라.

Answer (English): A single perceptron computes one linear boundary ($w^T x + b$), so it can only classify **linearly separable** data. XOR — $(0,0) \rightarrow 0$, $(1,1) \rightarrow 0$, $(0,1) \rightarrow 1$, $(1,0) \rightarrow 1$ — cannot be separated by any single straight line, so a single perceptron fails. Adding a **hidden layer** lets the network combine several linear boundaries into a **nonlinear** decision region, so an MLP can represent XOR. By the **Universal Approximation Theorem**, an MLP with even one hidden layer can approximate any continuous function. This 1969 limitation caused an “AI winter” until MLP + backpropagation revived neural networks.

모범답안 (한글): 단일 퍼셉트론은 선형 경계($w^T x + b$) 하나만 만들어 **선형 분리 가능한** 데이터만 분류할 수 있다. XOR — $(0,0) \rightarrow 0$, $(1,1) \rightarrow 0$, $(0,1) \rightarrow 1$, $(1,0) \rightarrow 1$ — 은 어떤 직선으로도 분리할 수 없어 단일 퍼셉트론으로 못 푼다. 은닉층을 추가하면 여러 선형 경계를 조합해 **비선형** 결정 영역을 만들 수 있어 MLP는 XOR을 표현할 수 있다. **보편근사정리**에 따르면 은닉층이 하나만 있어도 임의의 연속함수를 근사할 수 있다. 이 한계(1969)가 AI 겨울을 불렀고, MLP + 역전파로 신경망이 부활했다.

Q18. Why do we use a train-test split and K-fold cross-validation? Explain how using test data during preprocessing causes data leakage.

- (한글) 왜 train-test 분할과 K-겹 교차검증을 하는가? 전처리에 테스트 데이터를 쓰면 왜 data leakage가 되는지 설명하라.

Answer (English): A model evaluated on its own training data gives an over-optimistic score because it may simply memorize the data; this does not reflect **generalization** to new data. The test set — unseen during training — gives an unbiased estimate of real-world performance. **K-fold CV** splits the data into K folds, trains on K-1 and tests on the remaining fold, rotating K times and averaging the results; this reduces the variance caused by a single “unlucky” split and uses limited data efficiently. **Data leakage** happens when test information influences training — for example, computing normalization statistics (mean/std) over the *entire* dataset lets test information leak into training, producing falsely optimistic results. Preprocessing parameters must be estimated on the **training set only** and then applied to the test set.

모범답안 (한글): 모델을 자신의 훈련 데이터로 평가하면 데이터를 외웠을 수 있어 성능이 과대평가되며, 새 데이터에 대한 **일반화** 성능을 반영하지 못한다. 학습에 안 쓴 **테스트셋**은 실제 성능을 편향 없이 추정하게 해준다. **K-겹 CV**는 데이터를 K개로 나눠 K-1개로 학습·1개로 테스트를 K번 반복해 평균 내며, 한 번의 “운 나쁜 분할”에 따른 변동을 줄이고 한정된 데이터를 효율적으로 쓴다. **Data leakage**는 테스트 정보가 학습에 영향을 줄 때 생긴다 — 예: 정규화 통계(평균/표준편차)를 **전체** 데이터로 계산하면 테스트 정보가 학습에 새어 들어가 성능이 거짓으로 좋아 보인다. 전처리 파라미터는 **훈련셋에서만** 구해 테스트에 적용해야 한다.

Part 4. Problem Solving (2문항)

Q19. Compute the Euclidean distance between $a = (2, 4, 1)$ and $b = (5, 8, 2)$. Show all steps.

- (한글) 두 점 $a = (2, 4, 1)$, $b = (5, 8, 2)$ 사이의 유클리드 거리를 구하라. 풀이 과정을 보이라. (출제 확정)

Solution:

$$\begin{aligned} \text{dist}(a,b) &= \sqrt{(a_1-b_1)^2 + (a_2-b_2)^2 + (a_3-b_3)^2} \\ &= \sqrt{(2-5)^2 + (4-8)^2 + (1-2)^2} \\ &= \sqrt{(-3)^2 + (-4)^2 + (-1)^2} \\ &= \sqrt{9 + 16 + 1} \\ &= \sqrt{26} \\ &\approx 5.10 \end{aligned}$$

- (한글 주의) 각 차원 차이를 먼저 제곱해 더한 뒤 **마지막에 한 번만** 제곱근(sqrt). $\sqrt{26}$ 또는 ≈ 5.10 둘 다 정답으로 인정되는 경우가 많으나, 루트 안 정수(26)까지는 반드시 정확히.

Q20. Given a confusion matrix with $TP = 40$, $FP = 10$, $FN = 20$, $TN = 30$, compute Precision, Recall, F1-score, and Accuracy. Explain why accuracy alone can be misleading.

- (한글) 혼동행렬 $TP=40$, $FP=10$, $FN=20$, $TN=30$ 일 때 Precision, Recall, F1, Accuracy를 구하고, 정확도만으로는 왜 오해를 부를 수 있는지 설명하라.

Solution:

$$\begin{aligned}
 \text{Precision} &= TP / (TP + FP) = 40 / (40 + 10) = 40/50 = 0.80 \\
 \text{Recall} &= TP / (TP + FN) = 40 / (40 + 20) = 40/60 \approx 0.667 \\
 \text{F1} &= 2 \cdot P \cdot R / (P + R) = 2 \cdot 0.80 \cdot 0.667 / (0.80 + 0.667) \\
 &= 1.067 / 1.467 \approx 0.727 \\
 \text{Accuracy} &= (TP + TN) / (TP + TN + FP + FN) = (40 + 30) / 100 = 0.70
 \end{aligned}$$

Why accuracy can mislead: Accuracy weights every class equally, so on imbalanced data a high accuracy can hide poor performance on the minority (positive) class.

Precision, recall, and F1 focus on the positive class and reveal that trade-off.

- (한글) 정확도는 모든 클래스를 동등하게 반영하므로, 불균형 데이터에서는 높은 정확도가 소수 (양성) 클래스의 낮은 성능을 감출 수 있다. Precision/Recall/F1은 양성 클래스에 초점을 맞춰 그 한계를 드러낸다.

시험 직전 핵심 체크 (우선순위)

1. **Backprop 5단계 + forward pass**를 영어로 말할 수 있게 (Essay 최우선)
2. **Euclidean distance** 손계산 3세트 이상 연습 (확정)
3. **Confusion matrix** 지표 6개 공식 암기 + 숫자 계산
4. **KNN pseudocode / SVM margin 개념 / 단일 퍼셉트론 한계(XOR)**
5. **T/F 합정 10개(Part 1)** 통째로 훑기